
高级量化交易技术

闫涛
科技有限公司
北京 2021.05.08
{yt7589}@qq.com

第零篇深度学习

第 1 章行情数据处理

Abstract

在本章中我们将通过 AKshare 库，获取 A 股分钟级行情数据，并将其进行预处理，变为深度学习可用的数据集。

1 行情数据处理概述

1.1 获取原始行情数据

我们首先通过 `apps.fmts.ds.akshare_data_source.AkshareDataSource` 获取原始的行情数据，-将其保存到 csv 文件中。如果存在该 csv 文件，则直接从该文件中读出数据并返回。数据格式为：

```
1 .....
2 [ '2021-08-17 14:55:00' , 30.339999999999996 , 30.339999999999996 ,
   30.339999999999996 , 30.339999999999996 , 200.0]
3 [ '2021-08-17 14:55:01' , 30.339999999999996 , 30.339999999999996 ,
   30.339999999999996 , 30.339999999999996 , 200.0]
4 .....
```

Listing 1: 行情数据格式

1.2 行情数据预处理

1.2.1 价格折线图

我们以收盘价为例，收盘价的折线图绘制程序如下所示：

```
1 class OhlcvProcessor(object):
2     # 价格折线图模式
3     PCM_DATETIME = 1
4     PCM_TICK = 2
5
6     @staticmethod
7     def draw_close_price_curve(stock_symbol: str, mode=1) -> None:
8         '''
9         绘制收盘价折线图，横轴为时间，纵轴为收盘价
10        '''
11        data = AkshareDataSource.get_minute_bars(stock_symbol=
stock_symbol)
12        x = [v[0] for v in data[0:1000]]
13        y = [v[4] for v in data[0:1000]]
14        if mode == OhlcvProcessor.PCM_DATETIME:
15            OhlcvProcessor._draw_date_price_curve(x, y)
16        else:
17            OhlcvProcessor._draw_tick_price_curve(y)
18
19    def _draw_date_price_curve(x: List, y: List) -> None:
```

```

20     x = [datetime.datetime.strptime(di, '%Y-%m-%d %H:%M:%S')
for di in x]
21     fig, axes = plt.subplots(1, 1, figsize=(8, 4))
22     plt.rcParams['font.sans-serif']=['SimHei'] #用来正常显示中
文标签
23     plt.rcParams['axes.unicode_minus'] = False #用来正常显示负
号
24     # 最大化绘图窗口
25     figmanager = plt.get_current_fig_manager()
26     figmanager.window.state('zoomed') #最大化
27     # 绘制收盘价格折线图
28     axes.plot_date(x, np.array(y), '-', label='Net Worth')
29     # 设置横轴时间显示格式
30     axes.xaxis.set_major_formatter(DateFormatter('%Y-%m-%d %H
:%M:%S'))
31     plt.gcf().autofmt_xdate()
32     # 显示图像
33     plt.show()
34
35     def _draw_tick_price_curve(y: List) -> None:
36         x = range(len(y))
37         fig, axes = plt.subplots(1, 1, figsize=(8, 4))
38         plt.rcParams['font.sans-serif']=['SimHei'] #用来正常显示中
文标签
39         plt.rcParams['axes.unicode_minus'] = False #用来正常显示负
号
40         # 最大化绘图窗口
41         figmanager = plt.get_current_fig_manager()
42         figmanager.window.state('zoomed') #最大化
43         # 绘制收盘价格折线图
44         plt.title('收盘价折线图')
45         axes.set_xlabel('时间刻度')
46         axes.set_ylabel('收盘价')
47         axes.plot(x, np.array(y), '-', label='Net Worth')
48         plt.show()

```

Listing 2: 收盘价折线图

代码解读如下所示:

- 第 3、4 行: 定义收盘价曲线绘制方式, 一种是横轴为时间, 另一种横轴为行情序号;
- 第 6~10 行: 定义收盘价绘制方法, 参数为股票代码和绘制模式, 缺省值为横轴为时间 (以分钟为单位), 这种模式的缺点是从上一日收盘到下一日开盘有较大的时间间隔;
- 第 11 行: 获取分钟行情数据, 格式为: [[datetime, open, high, low, close, volume]];
- 第 19 行: 以横轴为行情时间值绘制收盘价曲线;

- 第 20 行：将时间变为'2021-08-21 12:56:00' 格式的列表；
- 第 21 行：设置显示图形；
- 第 22 行：设置字体使 matplotlib 可以正确显示汉字；
- 第 23 行：使 matplotlib 可以显示负号；
- 第 24~26 行：使 matplotlib 绘图窗口最大化；
- 第 27、28 行：绘制收盘价时间曲线；
- 第 29~31 行：设置横坐标轴时间显示格式为'2021-08-21 12:56:00'，并自动调整为 45 度角倾斜，以节省显示空间；

图 1: 以时间为横轴的收盘价折线图


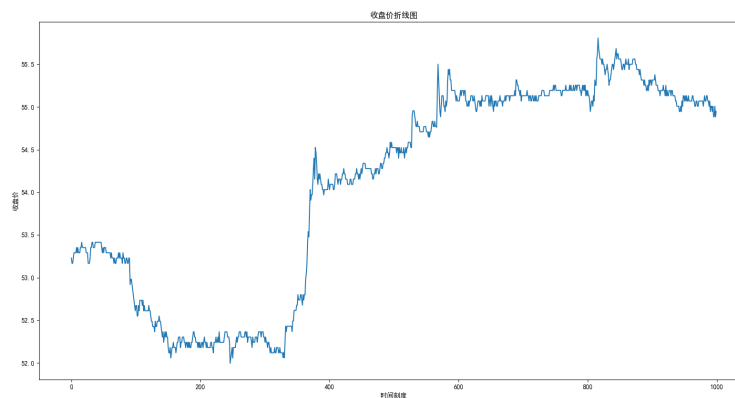


图 2: 以序号为横轴的收盘价折线图



如1所示，图中每天收盘到第二天开盘间没有行情数据，所以图形不太好看规律，而图2则可以较好的反映价格的变化规律，因此我们在通常情况下，选择图2的形式。

1.2.2 对数差分序列

我们都知道，原始的行情数据，不具备平稳性，即无法通过历史数据来预测未来，而对数差分序列则具有平稳性，可以用来进行预测。如下所示：

```

1 @staticmethod
2 def gen_1d_log_diff_norm(stock_symbol, items):
3     , , ,

```

```

4      从原始行情数据，求出一阶对数收益率 $\log(\text{day2}) - \log(\text{day1})$ ，然
      后求出每列均值和标准差，利用
5       $(x - \mu) / \text{std}$ 进行标准化，分别保存原始信息和归整后信息
6      参数：
7          stock_symbol 股票编号
8          items 由 AkshareDataSource.get_minute_bars 方法获取到
9          ,,,
10     datas = np.array([x[1:] for x in items])
11     log_ds = np.log(datas)
12     log_diff = np.diff(log_ds, n=1, axis=0)
13     log_diff_mu = np.mean(log_diff, axis=0)
14     log_diff_std = np.std(log_diff, axis=0)
15     ld_ds = (log_diff - log_diff_mu) / log_diff_std
16     # 保存原始信息
17     raw_file = './apps/fmts/data/{0}_1m_raw.txt'.format(
stock_symbol)
18     with open(raw_file, 'w', encoding='utf-8') as fd:
19         for item in items[1:]:
20             fd.write('{0},{1},{2},{3},{4},{5}\n'.format(item
[0], item[1],
21                                     item[2], item[3], item[4], item[5]))
22     # 保存规整化后数据
23     ld_file = './apps/fmts/data/{0}_1m_ld.csv'.format(
stock_symbol)
24     np.savetxt(ld_file, ld_ds)
25
26 # 测试程序
27 def test_gen_1d_log_diff_norm_001(self):
28     stock_symbol = 'sh600260'
29     items = AkshareDataSource.get_minute_bars(stock_symbol=
stock_symbol)
30     OhlcvProcessor.gen_1d_log_diff_norm(stock_symbol, items)

```

Listing 3: 收盘价折线图

代码解读如下所示：

- 第 2 行：items 由 AkshareDataSource.get_minute_bars 方法获取到，格式为 [..., ['2021-08-19 15:00:00', 1.1, 1.5, 1.0, 1.2, 1000], ...]；
- 第 10 行：把 items 中的条目，去除掉日期列后，生成 ndarray；
- 第 11 行：对所有元素取对数，以自然数 e 为底，np.log2 是以 2 为底，np.log10 是以 10 为底；
- 第 12 行：取一阶差分，其中 n=1 代表是一阶差分，即后面一个元素减前面一个元素， $\text{out}[i] = x[i+1] - x[i]$ ，因为 axis=0，所以 i 代表行；
- 第 13 行：求出行方向的均值；
- 第 14 行：求出行方向的标准差；

- 第 15 行：进行归一化： $\hat{x} = \frac{x-\mu}{\sigma}$ ；
- 第 18-21 行：保存原始的行情信息，因为取了一阶差分，所以去掉了第 1 行；
- 第 23、24 行：保存一阶差分规整化后的数据；

1.3 数据集支撑数据

在每一个时间点，我们向前看 `window_size` 个时间点，缺省是 10 个，然后再加上当前时间点的行情数据：开盘、最高、最低、收盘、交易量，所以共有 $10 \times 5 + 5 = 55$ 个数据，我们的算法会根据这 55 维向量，我们以当前时刻收盘价为标准，确定判断为上涨趋势的最低价格（一旦超过该值即视为上涨），判断为下跌的最高价格（一旦低于该值即视为下跌），向后连续读取指定个时刻，缺省值为 100，如果未来价格首先高于上涨趋势的最低价格，则将当前时刻判断为上涨状态，如果我们有资金，就应该进行买入操作；如果未来价格首先低于下跌趋势的最高价格，则将当前时刻判断为下跌状态，此时如果我们有持仓，则应卖出持有的股票，如果既没高于上涨趋势的最低价格，也没低于下跌趋势的最高价格，则将当前时刻判断为震荡状态，此时不进行任何操作。我们先来看数据的生成：

```

1  @staticmethod
2  def get_ds_raw_data(stock_symbol: str, window_size: int=10,
3  forward_size: int=100) -> Tuple[np.ndarray, np.ndarray, List[
4  str]]:
5      '''
6      获取数据集所需数据
7      stock_symbol 股票代码
8      window_size 从当前时间点向前看多少个时间点
9      forward_size 向后看多少个时间点确定市场行情是上涨、下跌和
10     震荡
11     返回值
12     X 连续11个时间点的OHLCV的数据，形状为n*55，一阶Log差分
13     形式
14     y 某个时间点及其前10个时间点行情数据组成的shapelet对应的
15     行情（按Box方式确定）：0-震荡；1-上升；2-下跌；
16     info 当前时间刻行情的真实值
17     '''
18     print('获取数据集数据')
19     # 获取行情数据
20     quotations = OhlcvProcessor.get_quotations(stock_symbol)
21     # 获取归整化行情数据
22     log_1d_datas = []
23     log_1d_file = './apps/fmts/data/{0}_1m_1d.csv'.format(
24     stock_symbol)
25     with open(log_1d_file, 'r', encoding='utf-8') as fd:
26         for row in fd:
27             row = row.strip()
28             arrs = row.split(' ')
29             item = [arrs[0], arrs[1], arrs[2], arrs[3], arrs
30             [4]]
31             log_1d_datas.append(item)

```

```

25     #
26     ldd_size = len(log_1d_datas) - forward_size
27     print('ldd_size: {}'.format(ldd_size))
28     X_raw = []
29     for pos in range(window_size, ldd_size, 1):
30         item = []
31         for idx in range(pos-window_size, pos):
32             item += log_1d_datas[idx]
33         item += log_1d_datas[pos]
34         X_raw.append(item)
35     X = np.array(X_raw, dtype=np.float32)
36     ds_X_csv = './apps/fmts/data/{0}_1m_X.csv'.format(
stock_symbol)
37     np.savetxt(ds_X_csv, X, delimiter=',')
38     # 获取行情状态
39     y = np.zeros((X.shape[0],), dtype=np.int64)
40     OhlcvProcessor.get_market_state(y, quotations, window_size
, forward_size)
41     # 获取日期和真实行情数值
42     raw_datas = []
43     raw_data_file = './apps/fmts/data/{0}_1m_raw.txt'.format(
stock_symbol)
44     seq = 0
45     with open(raw_data_file, 'r', encoding='utf-8') as fd:
46         for row in fd:
47             if seq >= window_size and seq < ldd_size:
48                 row = row.strip()
49                 arrs = row.split(',')
50                 item = [arrs[0], float(arrs[1]), float(arrs
[2]), float(arrs[3]), float(arrs[4]), float(arrs[5])]
51                 raw_datas.append(item)
52                 seq += 1
53     a1 = len(raw_datas)
54     return X[:a1], y[:a1], raw_datas

```

Listing 4: 获取数据集后面原始数据

2 最后

